

# 德州扑克教学机器人建议功能核心算法研究

围绕实现德州扑克教学机器人即时建议功能，本文系统分析四类核心算法：**当前手牌强度计算**、**提升潜力评估**、**牌力分桶**和**动作建议策略表生成**。每部分将介绍算法的核心思想、离线计算与在线查表适用性、在教学建议场景中的契合度（准确性、速度、可解释性），并提及可利用的现有工具。最后综合评估，推荐最适合教学系统的方案并给出结构设计与实现建议。

## 1. 当前手牌强度计算（Hand Strength）

**核心思想：**手牌强度通常指当前局面下手牌赢得摊牌的概率或胜率，即在未发完的牌局中，如果所有玩家一直看到摊牌，手牌获胜的频率。计算方法包括：

- **Monte Carlo模拟估计：**通过随机模拟剩余公共牌和对手手牌成千上万次，统计我方手牌胜率。这种方法利用计算机快速随机试牌的能力，“越多模拟次数结果越精确”<sup>1</sup>。例如，若模拟100万次发牌，统计我方获胜比例即可近似当前胜率。模拟法实现简单且适用于任意复杂局面，但精度取决于模拟次数，可能需要大量样本才能逼近真实概率。
- **穷举计算/查表：**对小规模问题可以枚举所有可能情况精确计算胜率。例如在翻牌面对单一未知对手时，可枚举所有剩余未知牌的组合来计算**Hand Strength (HS)**<sup>2 3</sup>。不过直接穷举计算可能非常耗时，需借助优化。例如**预计算查表法**：提前生成扑克手牌评估的查找表，将每个可能的5至7张牌组合映射到手牌强度或牌力排名。典型的是**TwoPlusTwo 评估器**，使用一个含约3248万条目的查找表（约250MB），通过多级索引实现对7张牌组合的单次查表即可得到强弱值<sup>4 5</sup>。这种“查表 + 状态机”算法极为高效，可在85毫秒内评估100,000手7张牌组合<sup>6 7</sup>——换算为每秒评估约百万手牌，远快于一般算法。
- **快速评估算法：**诸如Cactus Kev五张牌评估器或PokerStove库中的评估函数，通过位运算和动态规划避免重复计算。在7张牌情形下，TwoPlusTwo评估器被认为是最快的方法之一<sup>8</sup>。类似的快速评估算法可用于精确计算翻牌或转牌阶段的手牌胜率。例如对抗单一未知对手，在翻牌时枚举所有可能的对手两张底牌和未来两张公共牌，总共≈1225万种摊牌结果即可得出精确胜率。这对高效算法来说在1秒内是可完成的<sup>6 7</sup>。

**离线/在线适用性：**如果能将复杂计算离线完成，并将结果存入查表结构，则在线查询速度极快。比如预先生成某种局面下手牌胜率表。然而，由于德州扑克局面组合极其庞大，全面的胜率查表离线存储难度很高（特别是考虑多玩家和不同公共牌）。**折中方案**是离线存储常用子结果（如手牌牌力评估表），结合在线少量计算或抽样。例如使用TwoPlusTwo评估器离线构建7张牌强度评估表，然后在线枚举对手牌/未来牌时快速查询牌力。Monte Carlo模拟也可在线阶段实时进行——如果使用C/C++实现并合理限制模拟次数，可以在<1秒内完成上万甚至数十万次模拟，从而达到可接受的精度。模拟还可自适应：如根据时间预算动态调整样本数。

**契合度（准确率、速度、可解释性）：**手牌强度计算对建议系统至关重要，因为它提供了量化依据说明“我的牌现在有多好”。在教学情景中，可将**当前胜率**作为解释的一部分，例如“当前这手牌在此局面大约有80%的胜算”。精确度方面，借助穷举或高效算法可得到**精确胜率**，Monte Carlo则给**近似胜率**（误差随样本增多而减小）。在保证亚秒级响应下，上述方法都能达到较高准确率。TwoPlusTwo等算法的高效率使得精确计算在单挑场景成为可能<sup>9</sup>。可

解释性上，胜率数字本身直观易懂，可直接用于教学说明。不过，需要注意胜率是针对假设看到摊牌且对手范围均匀的计算，这在实际博弈中并非绝对决策标准，但对于教学有参考价值。

**现成工具：**有多种现有实现可利用：如开源的**TwoPlusTwo Hand Evaluator**（GPL协议，有第三方C++实现库）<sup>10</sup>、PokerStove的poker-eval库、以及Python封装的评估器。这些工具可直接用于计算手牌牌力排名或胜率。此外，很多在线计算器和开源项目实现了Monte Carlo equity计算和**Hand Strength**函数，可以集成到系统中。总之，在当前牌力计算方面，利用成熟评估库可以大幅加速开发。

## 2. 提升潜力评估（Potential / EHS）

**核心思想：**“提升潜力”衡量的是手牌未来两街（转牌、河牌）的改良空间和风险。当前手牌可能并非最强，但有一定机会通过后续发牌变强；反之，即使目前领先也可能被反超。为量化这些因素，扑克AI研究引入了**有效牌力（Effective Hand Strength, EHS）**概念<sup>11</sup>。EHS综合考虑了当前手牌强度和未来潜在变动，用0~1的数值表示综合胜率：

- **Hand Strength (HS):** 当前手牌强度，即**若马上摊牌**赢平局的概率<sup>2</sup><sup>3</sup>。计算方式如上节：枚举所有对手底牌，统计我手牌胜过对手的频率（平局算一半）得到HS值。
- **Positive Potential (PPot):** 正面潜力，当前落后时反超赢牌的概率<sup>12</sup>。即在未来两张公共牌发出后，如果起初我方是输牌，有多大概率改进成赢家<sup>13</sup>。简单理解就是“追上来的几率”，例如听牌完成的可能性。
- **Negative Potential (NPot):** 负面潜力，目前领先时被反超的概率<sup>12</sup>。即如果现在我方牌是最强，有多大概率后续公共牌导致对手后来居上<sup>13</sup>。

基于上述，**有效牌力 EHS**综合公式为：

$$EHS = HS \times (1 - NPot) + (1 - HS) \times PPot$$

<sup>11</sup> <sup>12</sup>。这代表综合考虑“如果现在赢且不被反超”以及“如果现在输但后来翻盘”的总概率。EHS直接给出当前手牌最终赢得摊牌的概率估计，比单看HS更全面。

**计算方法：**严格计算PPot/NPot需要枚举所有未来可能的转牌和河牌，并考虑每种情况下我方和对手牌力的变化<sup>14</sup><sup>15</sup>。这通常通过双重循环枚举（对手底牌组合 × 剩余公共牌组合）实现，计算量较大但对单挑场景可行。为简化，也可采用**Monte Carlo**采样法近似计算PPot/NPot：在当前翻牌情形下随机模拟很多次转牌+河牌，统计我方从落后翻盘次数和从领先被赶超次数，再估计PPot/NPot。另一个简化是**利用outs估算**：在翻牌时数出能改良我手牌的“outs”张数，用概率公式或经验法则近似提升概率。例如常用的“**2和4法则**”：翻牌有两张牌未发时，估计击中outs的概率约=outs数×4%；转牌后一张牌未发时≈outs数×2%<sup>16</sup><sup>17</sup>。比如翻牌听同花有9个outs，那么到河牌完成同花概率约9×4%=36%<sup>17</sup>。这种方法快速直观，误差在几个百分点内，对于教学解释足够易懂<sup>18</sup>。

**离线/在线适用性：**EHS计算相对昂贵，尤其在多玩家场景。不过，对于Heads-Up教学机器人，可以考虑**离线**预计算一些典型情形的潜力值。例如对常见翻牌类型，用均匀随机对手假设预先算出各种手牌组合的PPot/NPot，然后在在线阶段查表获取近似值。这类**Bucketing**的方法（见下一节），将有类似潜力分布的牌归类统一估算。另一思路是在线实时计算：若集成经过优化的EHS算法（比如使用C++扩展或GPU），在<1秒内对单挑计算PPot/NPot是可能的<sup>9</sup>。在实际系统中，**折中方案**可以是：“在线快速outs估算 + 离线精确EHS数据”：即时用outs给出大致潜力提示，同时后台利用精确算法核算更准确的胜率用于策略决策，不影响实时交互体验。

**契合度**：对教学建议而言，引入潜力评估能使建议更“智能”。**准确率**上，EHS明显优于仅看当前胜率HS，它能识别到听牌、后门听牌等隐含价值。例如纯HS可能低（当前牌弱），但PPot高意味着应该有进攻或跟注的理由——教学机器人可据此解释：“尽管目前不是最好的牌，但有相当大的改良机会（如还有35%的概率在河牌完成听牌）”。**速度**方面，通过预计算或高效实现，潜力评估可在建议生成时及时获得，不致拖慢响应。**可解释性**则是重点：潜力概念可以用直观语言阐释，如“**正面潜力**”对应常说的“XX张补牌(out)，完成概率约YY%”，**负面潜力**反映“即使现在领先也要防范对手反超的风险”。这些都可以转化为教学用语，增强用户对策略的理解。例如机器人建议：“目前你的牌力一般，但有9张补牌可以让你在河牌成为最强（大约36%的机会）<sup>17</sup>。因此可以考虑继续投入以追求听牌完成。”总体而言，潜力评估与教学解释天然契合，可以丰富建议的理由说明，使新手理解“不只是现在好坏，还要看未来可能”。

**现成工具**：早期知名扑克AI（如UAlberta的Loki/Poki）就应用了EHS算法，相关实现和伪代码公开可查<sup>11 14</sup>。开源项目方面，GitHub上有基于上述论文的EHS计算代码（例如Poker\_Effective\_Hand\_Strength项目，实现了HS、PPot、NPot的计算）<sup>19</sup>。这些代码通常以较低语言编写（C++/Java/PHP等）以加速计算，可移植到Python环境通过FFI调用。对于outs计算，许多教学资料或工具（如Odds计算器）都包含现成函数。总之，我们可以利用这些现有资源快速集成可靠的潜力评估模块。

### 3. 牌力分桶算法（Bucketing）

**核心思想**：由于德州扑克可能的具体牌局情况非常多，为简化决策策略，可以将“牌力特征相似”的手牌局面归为一类，用**桶（bucket）**表示。这样策略可以针对有限几个“手牌类型/等级”制定，而不需对每种组合逐一处理。在教学场景下，我们希望划分出**6~8个**直观的牌力桶，使每个桶内的手牌在强度和潜力上相近。常见的分桶思路包括：

- **基于二维特征聚类**：使用**当前牌力（如HS或即刻胜率）**和**未来潜力**两项指标，将翻牌时的手牌局面映射到二维特征点，然后应用聚类算法（如K-Means）自动分组<sup>20</sup>。例如，一个点代表“当前胜率50%、正面潜力30%、负面潜力10%”的手牌，在聚类中会归入和它特征相近的簇。K均值会尝试最小化同簇内差异，把牌力-潜力分布相似的手牌放一起<sup>20</sup>。这可以产生数据驱动的桶，比如可能出现“强成手类”、“弱成手但潜力大类”、“听牌类”等簇。聚类的桶数可以预先设定为6~8，以满足我们需求。
- **分位数分箱（Quantile Binning）**：一种简单方法是不借助复杂聚类，而是按照牌力数值直接分段。例如根据EHS或HS值把所有可能手牌局面从高到低排序，按百分比切分成若干档（每档包含近似相等数量的组合）。这样顶端10%的强牌一档，接下来20%一档，等等。这种方法实现简单且每档都有明确强度范围。但单纯按HS分可能忽略潜力差异，为此可对不同类型牌分别分箱（如成手牌按HS排序、听牌按成功率排序，各自分桶），或在分箱规则中综合考虑潜力（比如确保有一档专门留给听牌）。
- **Potential-aware Abstraction（潜力感知抽象）**：这是扑克AI研究中的高级方法，目标是让分桶不仅看当前胜率期望，还看胜率分布乃至未来走向。简单说，除了均值，还考虑分布的形状：如两手牌HS同为50%，但一手未来不是赢就是输（高方差），另一手经常55%胜率小赢（低方差），应归入不同桶。这类算法会利用更复杂的统计量（如HS的方差 $E[HS^2]$ 等）进行聚类分类，使得每个桶内手牌在完整分布上相似<sup>21</sup>。研究表明潜力感知的分桶比仅按期望值（distribution-aware）略优，在减少策略误差方面更有效<sup>21</sup>。然而实现复杂度也更高，通常需要定制的聚类算法（如基于Earth Mover's Distance的聚类等<sup>22</sup>）。对于教学系统，可能不必用如此复杂的方法，因为6~8个桶的粗粒度下，简单方法已能产出合理分组。
- **人工规则分组**：基于人工经验直接定义桶，也是可行且在教学中最直观的方法。例如预先定义6种手牌类型：“超强成手”（如大顶对以上）、“中等成手”（如第二对/顶对差踢脚等）、“边缘牌”（如小对或A高等有摊牌价值的弱成手）、“强听牌”（如坚实听牌，听同花顺或两高张+同花听等）、“弱听牌”（如后门听牌或卡顺

等）、“垃圾牌”（基本无赢牌希望）。这些类别对应常见策略教科书的术语。通过阈值或条件将任意局面归入相应类别，例如：“有顶对以上则属于强成手；无对但有4条同花则是强听牌”等。手工分桶优点是**易解释**——每个桶名和规则学生都能理解，而且桶数适中易记忆。缺点是可能不如数据驱动方法精细，边界划分也带主观因素，但鉴于教学侧重概念传递，这种牺牲是可接受的。

**离线/在线适用性：**大部分分桶工作可在离线完成。如采用K-Means聚类，需要准备大量代表性牌局数据（可以通过模拟生成），然后离线跑聚类得到簇中心及分配规则，最终产生一个映射函数： $f(\text{局面特征}) \rightarrow \text{桶ID}$ 。这映射函数可以是例如一张查表或一套决策树，在线根据当前局面计算HS、潜力特征后一查/一算即可得到桶ID，开销很小。如果是人工规则，则更简单：在线判断满足哪些条件，就选对应桶。这些规则本身就相当于离线定义好了。

**Bucketing**通常是**离线抽象、在线查表**的典型应用，非常适合低延迟要求。

**契合度：**在教学机器人中引入分桶，有助于策略的结构化和解释：

- **准确率影响：**适当的分桶不会显著降低策略准确性。在Heads-Up场景，6~8个桶虽然粗略，但可通过桶内行动混合来接近更细粒度策略。据研究，使用潜力感知的聚类能比简单均值分桶更贴近原始策略<sup>21</sup>。对于教学，略微降低精度换取简洁是可以接受的，只要确保明显不同的牌力不要被错分同一桶（避免建议失真）。
- **速度：**正如前述，在线桶分类非常快，仅涉及简单计算或查表，对实现1秒内响应几乎没有压力。
- **可解释性：**这是分桶在教学中的最大优势。每个桶可以赋予一个易懂的名称和策略含义。建议系统回答时，可以说“你的手牌属于X类型”，并配以该类型的一般策略原则解释。这比直接报数值更能让新手举一反三。例如：“你目前是强听牌（属于我们的第4类牌），**潜力**很大但目前还没成手，根据策略应采取进取打法（比如半池下注施压）”。这种类别化解释使抽象的概率策略转化为了具象的概念，极大提升教学效果。

**现有工具/实践：**扑克牌力抽象是研究热点，公开资料包括University of Alberta关于分桶效果的论文<sup>21</sup>以及社区实践分享。例如Poker-AI论坛提到业界**常用K-Means聚类**进行翻牌/转牌牌力分桶，甚至具体建议“翻牌和转牌用distribution-aware，河牌用OCHS或直接按赢牌/听牌率分就够粗略了”<sup>21</sup>。“OCHS”即一种简单评估指标（估计是**优化当前手牌强度**），总之也强调了听牌（draw%）的重要性<sup>21 23</sup>。这些经验都可借鉴。此外，如果不想自行实现，可以参考开源的德州扑克AI项目（如Flopzilla等工具的输出分类）或者教学资料，将其分类逻辑转化为代码。在实现人工规则时，也可邀请扑克教练参与制定规则，确保每个桶定义符合教学共识。

## 4. 动作建议策略表生成

**核心思想：**这是整合前述要素形成“**状态** → **建议**”映射的关键步骤。目标是构建一个策略查询表，输入当前局面的特征，输出推荐的动作（例如check, bet 1/2 pot, fold等）和可能的频率/权重。核心在于如何得到这样一张策略表：

- **基于规则的映射：**人工制定规则，将局面特征映射到动作建议。这些规则通常结合经验和一定的理论依据，比如**范围优势+SPR+牌面纹理**等因素。具体方法是先定义一系列维度，比如：底池类型（单挑底池、3bet底池等）、我方位置（IP/OOP）、当前牌面纹理（干燥/协调、高牌大小等）、SPR大小（筹码相对底池深度），再加上我方手牌桶类别。根据这些维度的组合，为每种情况指定一个策略。**示例：**“单挑加注底池，干燥高牌面，位置在后（IP），SPR较深，我方有强听牌或中等成手：建议持续下注1/3底池；如果是边缘牌则过牌控池”。这一规则其实在人类教学中常见（干燥牌面范围优势方小下注持续进攻）。类似地，可以为其他情形制定规则。**优势：**规则法完全适合**离线生成**——专家或开发者编写规则列表即可。**在线阶段**只是根据当前状态检索匹配的规则节点，输出建议，速度极快。对于教学，这种方式**高度可解释**：因为每条建议背

后都有清晰的条件和原理，可以直接转换成解释语句（例如上述规则的解释：“因为这是干燥牌面且你在位置优势，理论上进攻频率高，所以建议你下注...”）。**不足**：规则质量取决于专家经验，可能与GTO最佳有偏差。但在教学机器人场景，我们追求的是“合理且易讲解”的策略，规则法能够嵌入大量教学观点（如“SPR高时不要轻易全压”等），即使不完全最优，也能培养正确思维。

- **基于求解器的策略表**：利用**线性规划（序列式）**或**策略迭代算法（如CFR, Monte Carlo CFR）**在抽象游戏上求解近似的平衡策略，然后提取为查表。这是现代顶尖AI的做法。具体而言，可先基于前述的**分桶**和有限动作集合构建一个简化的决策树模型，然后用二人零和解算方法求取纳什均衡策略<sup>24</sup>。比如，可设定翻牌阶段只有check或下注1/2pot两种行动，每方手牌用6个桶表示，那么该局面的状态空间就大幅缩小，可以用LP求解每个桶采取各行动的最优概率。这些解算可以完全离线执行，得到的结果是一个**策略矩阵**（或策略表），描述在每种抽象状态下各动作的概率。生成后，我们可以**固化**这个策略，在机器人中查表使用。**优势**：此策略源自计算，理论上**最平衡最难被利用**，作为教学可称“GTO基准”。对于那些要求高的用户，这是权威参考。**并且**，均衡策略带有**混合频率**（例如某情形下70%下注/30%过牌），这恰是扑克策略重要概念，教学时可提示玩家策略并非绝对单一路径。**劣势**：直接呈现混合策略给新手可能过于复杂，而且机器求解出来的策略缺乏直观解释——为什么不是100%一种动作往往很抽象（需要理解平衡、范围概念）。为了教学友好，机器人可以将**主要动作**作为建议，但同时提示“有时也可以选择另一动作以平衡”之类的频率说明<sup>25</sup><sup>26</sup>。实现上，求解器需要投入相当计算资源，特别是无极德州扑克完整游戏太大无法完全求解。所以实际应用中，多采用**局部均衡解**：例如预先用专业软件（如PioSolver、MonkerSolver）解若干**典型场景**（不同牌面、不同SPR等）的策略，然后将这些解以某种方式泛化到机器人策略表中。另一途径是**逐街分解**：先求解简化的翻牌策略，固定后再求转牌.....虽然不完美但简化实现。总体看，纯求解器路线对开发要求高，不如规则法直接，但混合两者也有可能：**用均衡数据指导规则制定**，即**先从解算结果中总结规律**，再转化为规则表。这实际是目前很多教学和GTO工具的思路。

- **混合概率策略表结构**：无论规则制定还是求解得到策略，我们都需要将策略以适当的数据结构存储，以便**快速查找且支持混合策略**。根据设计，可以采用**JSONL + SQLite**的组合存储：即将策略表的每个节点（定义一组条件下的动作概率）存为一行JSON（便于人工阅读编辑），同时在SQLite中建立索引（如组合键`street/pot_type/role/texture/spr/hand_class`）<sup>27</sup>来高效查询。查询输入当前局面属性拼接成键，直接从索引获取对应JSON节点，然后解析出建议动作。JSON内容可以包括一个动作或一个动作混合列表带权重<sup>28</sup><sup>29</sup>。如果是混合策略，系统还需决定具体执行哪个动作：可采用**确定性随机方法**，即通过固定的随机种子（例如当前局面的唯一ID）生成伪随机数，按权重选择动作<sup>27</sup>。这样保证相同局面每次建议一致（避免教学时因为随机波动产生困惑），同时长远看又保留频率性质，不会始终采取同一纯动作<sup>26</sup><sup>30</sup>。如果混合策略让用户难以消化，也可配置为**关闭混合模式**，系统总是选择权重最大的动作作为建议<sup>26</sup>。这种表驱动结构完全符合**离线计算、在线查表模式**：策略的生成和优化都在离线完成，并可由开发者审阅调整；在线查询时只是几个索引查询和简单的逻辑，耗时可以做到毫秒级。对于教学解释，策略表的每个节点还可以预存一段**理由模板**（或代码）用于说明。例如某节点包含字段`"plan": "持续下注：干燥牌面范围优势"`之类提示，可被渲染到解释UI中。通过这种方式，每条建议都能给出预先准备的、符合教学的解释文本，确保**结构清晰、解释丰富**，这是规则/查表法相比黑盒计算的巨大优势。

**契合度**：策略表法几乎是教学机器人量身定制的架构。它保证**<1s响应**：查数据库+简单逻辑非常快。**结构清晰**：策略以表格/树形式存在，易于维护和调试，出问题可以直观修改。**解释丰富**：结合键值和预存文案，可以针对当前局面对症下药地解释策略。“建议策略表”还能方便地扩展内容，例如在记录中加入**信心度**或**备选方案**等辅助信息传递给用户。唯一需要平衡的是**准确性**：规则表若纯靠人工，难免有偏差；而纯算解表或大规模Solver输出又可能不便于解释。为此，**混合法最佳**：**以GTO解为基准，辅以规则调整**。比如基础策略用Solver数据填充，但在特殊情况处插入人工规则以处理Solver未覆盖或易讲解的情况（正如计划里也提到的当无规则匹配时用保守fallback<sup>31</sup>）。因此，一个精心设计的策略表既能**保持策略合理性**（参考GTO不会跑偏），又能**保证解释友好**（通过规则注释）。对于教学机器人而言，这种方案能提供一致且可靠的建议，同时将晦涩的博弈论策略转化为用户听得懂的语言。

**现成代码/工具：**虽然没有现成的完整“策略表生成器”，但我们可借鉴很多来源。**商业GTO解算器**（如GTO+、PIO Solver）可以求解并导出策略数据，我们可以编写脚本把这些数据转换为自己的JSON表格式。在规则引擎方面，通用的规则引擎（如Drools等）也可用来管理复杂条件-动作映射，但定制JSON更轻量。值得注意的是，用户提供的文件【24】中已经有详细的策略表结构设计，包括节点键分类、混合策略存储和确定性随机实现细节<sup>25</sup><sup>27</sup>。这套设计本身就是强有力的指导，我们可以直接按照类似思路构建。此外，很多开源扑克机器人项目（如PokerSNAP等）虽没有教学解释，但也采用了策略表/树配置，可参考其数据组织方式。在实现策略表时，也要考虑版本管理和易于更新——采用JSONL文本就是为了方便人工调整，而用SQLite索引则保证查询速度，这种组合在实践中被证明行之有效。

## 5. 最佳方案选择与实现建议

综合以上分析，我们推荐采用“快速牌力计算 + EHS潜力评估 + 简洁牌力分桶 + 策略查表”的组合方案来实现教学机器人的建议功能。这一方案在确保决策合理性的同时，注重解释透明和系统响应速度，具体建议如下：

- **实时计算与查表相结合，保证<1秒响应：**采用底层高效算法（如TwoPlusTwo牌力评估器）实时计算当前手牌胜率 and 主要听牌概率，辅以简单outs公式校验，使机器人对当前牌情了然于胸<sup>9</sup><sup>17</sup>。其余复杂决策逻辑全部查表完成——当前局面的抽象分类（桶、局面键）与预先生成的策略表快速匹配，返回建议。这样的架构下，在线阶段的计算量极小，不管用户何时请求建议，系统都能在不到1秒内给出答案。
- **离线预备全面，构建模块化策略知识库：**在开发过程中，大量工作放在离线：用模拟和工具生成手牌HS/EHS数据，用聚类或专家知识制定分桶规则，用Solver和教练经验编写策略表。建议将这些离线产物组织成清晰的配置数据，例如：`hand_strength_lookup`（牌力评估表）、`hand_bucket_rules`（分桶规则定义）、`strategy_table.jsonl`（策略节点列表）等。通过模块化配置，日后可以针对教学反馈微调某部分而不影响其他部分（例如发现某类牌建议过松，就修改对应规则或节点）。同时离线使用版本控制管理策略数据，确保每次更新都有记录可追溯。
- **使用直观的6~8类牌力桶贯穿策略与解释：**将手牌强度和潜力抽象为有限几类，使之成为策略表和解释文本的“纽带”。比如策略表键的最后一维就是`hand_class`（手牌类别），对应解释模板里会引用这个类别名称<sup>27</sup>。确保桶的定义符合直觉并在UI上有所呈现，让用户逐步熟悉这些类别。从实现看，预先定义好每个桶的名称和判定条件，在代码中实现一个函数`get_hand_class(手牌, 公共牌)`返回类别即可。由于桶分类已简化了情况，策略表规模也会相应减少，方便维护。在我们建议的方案中，**牌力桶是核心桥梁**：既减少策略复杂度，又提供了解释抓手，应投入足够精力设计。
- **策略表以规则为骨架、以GTO数据为参考：**考虑到教学需要解释原因，策略表中的每个节点（状态）都应当有类人可理解的决策依据。因此，建议首先由专家拟定各典型情境的策略（规则骨架），然后对照GTO解算结果进行校准。例如，专家规则认为“干燥A高翻牌，前位下注范围广，应小注持续下注”，与Solver印证确实大部分情况下如此。如有出入，再分析原因调整。最终策略表既包含**确定性的**动作建议，也在需要时附带**频率信息**（对于GTO需混合的节点，储存mix权重）<sup>30</sup>。实现时，可扩展策略表JSON schema，让每个节点支持`mix`数组或`freq_hint`<sup>29</sup>。机器人默认给主要动作，必要时在解释中通过`freq_hint`提示“此情况下有X%的几率选择其他行动以平衡”。
- **确定性随机混合策略确保教学连贯：**对于有混合策略的节点，实现**稳定的随机选择**<sup>27</sup>。推荐利用当前`hand_id`或局面哈希作为随机种子，使相同局面每次出现建议一致<sup>27</sup><sup>26</sup>。这避免了用户重复询问时得到不同答案的困惑，又在不同手牌时贯彻策略频率。例如某情境设定75%下注、25%过牌，代码通过哈希实现每四次有一次给出过牌建议，从长远看接近既定频率，但单一用户体验看每次都有明确指示，不干扰教学连

贯性。实现上，可采用如MurmurHash3等高效哈希<sup>32</sup>并对权重区间取值。这部分逻辑可封装为 `choose_action_by_weight(state_key, weights)` 工具函数，使得在策略表检索出mix后，一行代码得到最终动作。

- **预设解释模板，做到每条建议“知其然并知其所以然”**：建议功能的价值在于教学，因此实现中要为**每个策略节点和规则**编写易懂的解释模板。模板可带占位符插入当前信息，如：“干燥{texture}牌面下，你在{role}位置拥有{hand\_class}，策略倾向于{action}（原因：...）”。在输出建议时，填充模板并配合关键数据（如当前胜率X%，潜力Y%等）<sup>18</sup>，形成完整说明。这要求策略表或相关配置中存储这些模板字符串和所需数据。实现上，可以在策略JSON里加入 `"explanation": "..."` 字段，或者维护一个 `explanation_templates` 字典按键匹配。关键是解释内容应与算法逻辑同步更新，避免建议和理由不一致。另外，还应保持措辞简洁，段落适当分段，让用户容易消化（这一点在前端展示时考虑）。
- **利用已有库与持续测试**：在具体编码时，充分利用前述现有库：例如集成TwoPlusTwo C++库计算HS/EHS，通过SQLite高效索引JSON策略表，使用NumPy/Pandas等分析工具辅助离线聚类分桶验证策略覆盖等。同时，为确保准确和快速，每次策略或算法调整后都进行大量模拟测试。例如随机采样上万种局面，通过机器人建议与真实Solver建议对比，统计匹配率，找出偏差大的情形针对性改进。这种测试保证最终方案在**教学友好**的前提下，策略表现也足够**科学可信**。

综上，采用上述方案将能够实现一个性能达标、结构清晰、解释充分的德州扑克教学机器人建议系统：在不到1秒内，它不仅能告诉用户“**此刻应该做什么**”，更会告诉用户“**为什么这么做**”，背后依据包括当前牌力计算结果<sup>9</sup>、未来潜力评估<sup>17</sup>以及策略表中蕴含的博弈论原理。这正是我们追求的教学效果，也是本方案最突出的价值所在。每当用户面临决策，系统快速给出动作建议的同时，配以层次分明的讲解，帮助用户逐步建立正确的决策思维模型，实现技能提升。通过不断打磨和扩展这一体系，最终可以覆盖德州扑克各阶段的策略指导，成为用户可靠的线上教练。<sup>33</sup> <sup>27</sup>

---

#### <sup>1</sup> How Does software calculate Equity - Poker Theory

<https://forumserver.twoplustwo.com/15/poker-theory-amp-gto/how-does-software-calculate-equity-1799520/>

#### <sup>2</sup> <sup>3</sup> <sup>11</sup> <sup>12</sup> <sup>13</sup> <sup>14</sup> <sup>15</sup> Effective hand strength algorithm - Wikipedia

[https://en.wikipedia.org/wiki/Effective\\_hand\\_strength\\_algorithm](https://en.wikipedia.org/wiki/Effective_hand_strength_algorithm)

#### <sup>4</sup> <sup>5</sup> <sup>6</sup> <sup>7</sup> <sup>8</sup> <sup>9</sup> sv-Incs

<https://paginas.fe.up.pt/~prodei/dsie11/images/pdfs/s3-4.pdf>

#### <sup>10</sup> What are you using under the hood? I've been using poker-eval for a ...

<https://news.ycombinator.com/item?id=23742021>

#### <sup>16</sup> <sup>17</sup> <sup>18</sup> The Rule Of 4 And 2 | The 2/4 Pot Odds Shortcut

<https://www.thepokerbank.com/strategy/mathematics/pot-odds/4-2/>

#### <sup>19</sup> GitHub - Weedshaker/Poker\_Effective\_Hand\_Strength: Calculate the hand strength [EHS = HS x (1 - NPOT) + (1 - HS) x PPOT] and hand potential by algorithm from [https://en.wikipedia.org/wiki/Poker\\_Effective\\_Hand\\_Strength\\_%28EHS%29\\_algorithm](https://en.wikipedia.org/wiki/Poker_Effective_Hand_Strength_%28EHS%29_algorithm)

[https://github.com/Weedshaker/Poker\\_Effective\\_Hand\\_Strength](https://github.com/Weedshaker/Poker_Effective_Hand_Strength)

#### <sup>20</sup> <sup>21</sup> <sup>23</sup> <sup>24</sup> Poker-AI.org :: View topic - bucketing

<https://poker-ai.org/phpbb/viewtopic4bf.html>

22 [PDF] Potential-Aware Imperfect-Recall Abstraction with Earth Mover's ...

[https://www.cs.cmu.edu/~sandholm/potential-aware\\_imperfect-recall.aaai14.pdf](https://www.cs.cmu.edu/~sandholm/potential-aware_imperfect-recall.aaai14.pdf)

25 26 27 28 29 30 31 32 33 GTO\_suggest\_feature\_rebuild\_plan.md

<file:///file-ScyJupkLtkq7QCGv8vgq2>